

LAB 3. Statistik Deskriptif dan Distribusi Data

1. CPMK dan SubCPMK

CPMK-1018 - Mampu melakukan exploratory data analysis (EDA) dan menerapkan statistik deskriptif untuk analisis data.

Sub-CPMK

1) Mahasiswa mampu memahami dan menerapkan konsep statistik deskriptif dalam analisis data.

Indikator capaian pada SubCPMK ini adalah mahasiswa memiliki kemampuan untuk:

- menghitung measures of central tendency (mean, median, mode)
- menghitung measures of variability (variance, standard deviation, range)
- menganalisis distribusi data
- menghitung percentiles dan quartiles
- menginterpretasikan hasil analisis statistik

Kata kunci penting: **menginterpretasi**, bukan sekadar menghitung

2. Dasar Teori

Statistik Deskriptif


Statistik deskriptif merupakan cabang dari statistik yang digunakan untuk mengumpulkan, mengolah, menyajikan, dan menganalisis data sehingga dapat memberikan gambaran yang jelas mengenai karakteristik suatu dataset. Dalam konteks analitik data, statistik deskriptif berfungsi sebagai tahap awal dalam memahami data sebelum dilakukan analisis yang lebih lanjut seperti exploratory data analysis (EDA), pemodelan data, maupun pembuatan visualisasi.

Statistik deskriptif tidak bertujuan untuk melakukan generalisasi terhadap populasi, melainkan untuk memberikan ringkasan informasi dari data yang tersedia. Informasi yang dihasilkan dapat berupa nilai rata-rata, penyebaran data, distribusi nilai, serta pola-pola tertentu yang terdapat dalam dataset.

Dalam praktik analitik data, statistik deskriptif memiliki peran yang sangat penting karena:

- membantu memahami struktur dan karakteristik data
- mengidentifikasi adanya nilai yang tidak wajar (outlier)
- memberikan gambaran awal mengenai pola distribusi data
- menjadi dasar dalam pengambilan keputusan berbasis data

Dengan menggunakan statistik deskriptif, analisis data dapat memperoleh pemahaman awal yang kuat terhadap dataset sebelum melanjutkan ke tahap analisis yang lebih kompleks.



Gambar 1.1 Perbandingan Mean, Median, dan Mode pada Berbagai Bentuk Distribusi

Measures of Central Tendency (Ukuran Pemusatan Data)

Measures of central tendency atau ukuran pemusatan data merupakan metode statistik yang digunakan untuk menentukan nilai representatif dari suatu kumpulan data. Nilai ini dianggap sebagai pusat distribusi data dan sering digunakan untuk menggambarkan kondisi umum dari dataset.

Terdapat tiga ukuran pemusatan yang umum digunakan, yaitu mean, median, dan mode.

1) Mean (Rata-rata)

Mean adalah nilai rata-rata yang diperoleh dengan menjumlahkan seluruh nilai dalam dataset kemudian dibagi dengan jumlah data. Mean sering digunakan karena mudah dihitung dan memberikan gambaran umum mengenai nilai data. Namun, mean memiliki kelemahan yaitu sangat sensitif terhadap nilai ekstrem (outlier). Jika terdapat nilai yang sangat besar atau sangat kecil, maka nilai mean dapat menjadi tidak representatif terhadap keseluruhan data.

2) Median (Nilai Tengah)

Median adalah nilai tengah dari dataset setelah data diurutkan dari nilai terkecil ke terbesar. Jika jumlah data ganjil, median adalah nilai di tengah. Jika jumlah data genap, median adalah rata-rata dari dua nilai tengah. Median lebih stabil dibandingkan mean karena tidak terpengaruh secara signifikan oleh outlier. Oleh karena itu, median sering digunakan untuk data yang memiliki distribusi tidak normal atau mengandung nilai ekstrem.

3) Mode (Modus)

Mode adalah nilai yang paling sering muncul dalam dataset. Mode biasanya digunakan untuk data kategorikal atau untuk mengetahui nilai yang paling dominan dalam suatu dataset. Dalam beberapa kasus, dataset dapat memiliki lebih dari satu mode (multimodal) atau bahkan tidak memiliki mode sama sekali.

Pada praktik nyata misalnya pada data penjualan, mean yang lebih besar dibandingkan median menunjukkan bahwa distribusi data cenderung miring ke kanan (positively skewed). Biasanya disebabkan oleh adanya beberapa transaksi dengan nilai yang sangat tinggi. Median lebih mencerminkan nilai transaksi yang umum terjadi dibandingkan mean karena tidak terpengaruh oleh nilai ekstrem. Dalam analisis bisnis, penggunaan mean sebagai representasi nilai transaksi dapat menyesatkan apabila terdapat outlier. Oleh karena itu, median lebih tepat digunakan untuk menggambarkan perilaku transaksi mayoritas pelanggan.


Measures of Variability (Ukuran Penyebaran Data)

Measures of variability atau ukuran penyebaran data digunakan untuk mengetahui seberapa jauh data tersebar dari nilai pusatnya. Ukuran ini penting karena dua dataset dapat memiliki nilai rata-rata yang sama, tetapi memiliki tingkat penyebaran yang berbeda.


Beberapa ukuran penyebaran yang umum digunakan antara lain:

1) Range (Rentang Data)

Range adalah selisih antara nilai maksimum dan nilai minimum dalam dataset. Range memberikan gambaran sederhana mengenai seberapa luas penyebaran data. Meskipun mudah dihitung, range memiliki kelemahan karena hanya mempertimbangkan dua nilai ekstrem dan tidak memperhitungkan distribusi data secara keseluruhan.




Gambar 1.2 Range dari skor



Gambar 1.3 Range dari grafik batang

2) Variance (Variansi)

Variance adalah ukuran yang menunjukkan seberapa jauh setiap nilai dalam dataset menyimpang dari nilai rata-rata. Variance dihitung dengan mengambil rata-rata dari kuadrat selisih antara setiap nilai dengan mean. Variance memberikan informasi mengenai tingkat variasi data, namun satuannya berupa kuadrat dari satuan asli data sehingga sulit diinterpretasikan secara langsung.




Gambar 1.4 Variance

Variance merupakan ukuran statistik yang menunjukkan tingkat penyebaran data terhadap nilai rata-rata (mean, μ), yang pada gambar divisualisasikan melalui kurva distribusi normal (bell curve). Pada kurva di gambar 1.4, area di sekitar mean menunjukkan konsentrasi data, di mana sekitar 34,1% data berada di setiap sisi dalam rentang ± 1 standar deviasi, sehingga total 68,2% data terkonsentrasi dekat mean. Selanjutnya, sebesar 13,6% data berada pada rentang antara 1 hingga 2 standar deviasi, dan semakin ke luar, hanya sebagian kecil data yang berada pada rentang ekstrem (sekitar 2,1% hingga 0,1%). Hal ini menunjukkan bahwa semakin jauh data dari mean, semakin kecil probabilitas kemunculannya. Dengan demikian, variance menggambarkan seberapa lebar penyebaran data: variance kecil menghasilkan kurva yang lebih sempit dan tinggi (data homogen), sedangkan variance besar menghasilkan kurva yang lebih lebar (data lebih bervariasi), sehingga penting dalam menilai konsistensi dan stabilitas suatu dataset.

3) Standard Deviation (Simpangan Baku)

Standard deviation merupakan akar kuadrat dari variance. Nilai ini lebih mudah diinterpretasikan karena memiliki satuan yang sama dengan data asli. Standard deviation digunakan untuk mengukur seberapa besar variasi atau penyebaran data. Nilai standard deviation yang kecil menunjukkan bahwa data cenderung berkumpul di sekitar mean, sedangkan nilai yang besar menunjukkan bahwa data tersebar lebih luas.



Gambar 1.5 Mean, Variance, dan Standar Deviasi

Pada gambar 1.5, ditampilkan visualisasi distribusi data yang menunjukkan hubungan antara mean, variance, dan standard deviation. Mean (rata-rata) ditunjukkan oleh garis vertikal merah putus-putus di tengah dengan nilai sekitar 50,9, yang merepresentasikan pusat distribusi data. Standard deviation (simpangan baku) ditunjukkan oleh dua garis hijau putus-putus di kiri dan kanan mean (sekitar 41,78 dan 60,03), yang menggambarkan jarak rata-rata penyimpangan data dari mean. Sementara itu, variance (varians) ditampilkan sebagai nilai numerik sebesar 83, yang merupakan kuadrat dari standar deviasi dan digunakan untuk mengukur tingkat penyebaran data secara keseluruhan. Dengan demikian, mean menunjukkan titik pusat data, sedangkan standar deviasi dan varians menunjukkan seberapa besar variasi atau penyebaran data terhadap nilai rata-rata.

Dalam penggunaannya, misalnya hasil perhitungan menunjukkan bahwa:

- nilai standard deviation relatif tinggi
- variance menunjukkan tingkat penyebaran data yang besar
- range antara nilai minimum dan maksimum sangat lebar

Nilai standard deviation yang tinggi menunjukkan bahwa terdapat variasi yang signifikan dalam nilai transaksi pelanggan. Hal ini menunjukkan bahwa data tidak homogen dan memiliki tingkat penyebaran yang luas. Range yang besar juga mengindikasikan adanya perbedaan yang signifikan antara transaksi terkecil dan terbesar.

Variabilitas yang tinggi dalam data transaksi menunjukkan adanya segmentasi pelanggan, seperti:

- pelanggan dengan transaksi rendah (low-value customers)
- pelanggan dengan transaksi tinggi (high-value customers)

Hal ini penting dalam strategi bisnis, khususnya dalam penentuan segmentasi pasar dan strategi pemasaran.

Percentiles dan Quartiles

Percentiles dan quartiles merupakan ukuran statistik yang digunakan untuk membagi data yang telah diurutkan menjadi beberapa bagian guna memahami distribusi dan penyebaran data. Percentile menunjukkan posisi relatif suatu nilai dalam dataset, di mana persentil ke-50 (50th percentile) disebut sebagai median yang membagi data menjadi dua bagian sama besar. Quartile merupakan pembagian khusus dari percentile yang membagi data menjadi empat bagian, yaitu kuartil pertama (Q1) pada persentil ke-25, kuartil kedua (Q2) yang sama dengan median (persentil ke-50), dan kuartil ketiga (Q3) pada persentil ke-75. Rentang antara Q1 dan Q3 disebut interquartile range (IQR), yang menggambarkan sebaran 50% data tengah dan sering digunakan untuk mendeteksi outlier. Dengan demikian, percentile dan quartile membantu dalam memahami posisi, distribusi, serta variasi data secara lebih mendalam dibandingkan hanya menggunakan nilai rata-rata.

Percentiles dan quartiles digunakan untuk membagi dataset menjadi beberapa bagian berdasarkan distribusi nilai.

1) Quartiles

Quartiles membagi data menjadi empat bagian yang sama besar, yaitu:

- Q1 (kuartil pertama): 25% data berada di bawah nilai ini
- Q2 (median): 50% data berada di bawah nilai ini
- Q3 (kuartil ketiga): 75% data berada di bawah nilai ini

Quartiles sering digunakan untuk memahami distribusi data dan sebagai dasar dalam pembuatan boxplot.

2) Percentiles


Percentiles membagi data menjadi 100 bagian yang sama besar. Sebagai contoh, percentile ke-90 menunjukkan bahwa 90% data berada di bawah nilai tersebut. Percentiles digunakan dalam berbagai bidang seperti analisis performa, evaluasi nilai, dan analisis distribusi data.

Contoh penggunaannya, misalnya berdasarkan hasil perhitungan quartile:

- Q1 menunjukkan batas bawah 25% data
- Q2 (median) menunjukkan nilai tengah

- Q3 menunjukkan batas atas 75% data

Dengan membagi menjadi quartile, kita bisa melihat sebagian besar data berada di bawah nilai Q3, sementara nilai maksimum jauh melebihi Q3. Hal ini menunjukkan bahwa terdapat nilai-nilai ekstrem di luar distribusi utama data. Sehingga nilai Q3 dapat digunakan sebagai acuan untuk mengidentifikasi pelanggan dengan nilai transaksi tinggi. Dalam konteks bisnis, kelompok ini dapat dikategorikan sebagai pelanggan potensial yang memiliki kontribusi besar terhadap pendapatan.



Gambar 1.6 Percentiles dan Quartiles

Distribusi Data

Distribusi data menggambarkan bagaimana nilai-nilai dalam dataset tersebar. Pemahaman terhadap distribusi data sangat penting dalam analisis data karena dapat membantu dalam menentukan metode analisis yang tepat.

Beberapa jenis distribusi data yang umum antara lain:

1) Distribusi Normal

Distribusi normal adalah distribusi yang simetris dengan bentuk menyerupai lonceng (bell curve). Pada distribusi ini, nilai mean, median, dan mode berada pada posisi yang sama.

2) Distribusi Miring (Skewed Distribution)

Distribusi dikatakan miring jika data tidak simetris, yaitu:

- Skewed ke kanan (positif): ekor distribusi memanjang ke kanan
- Skewed ke kiri (negatif): ekor distribusi memanjang ke kiri

Distribusi yang miring menunjukkan bahwa data tidak tersebar secara merata.

Untuk melihat distribusi data apakah normal atau miring, dapat menggunakan histogram. Histogram dapat menunjukkan distribusi data dengan pola yang tidak simetris atau cenderung miring ke kanan (right skewed). Distribusi yang miring ke kanan menunjukkan bahwa sebagian besar data terkonsentrasi pada nilai rendah, sementara terdapat sejumlah kecil data dengan nilai yang sangat tinggi.


Distribusi seperti ini umum ditemukan pada data transaksi e-commerce, di mana:

- mayoritas pelanggan melakukan transaksi kecil

- sebagian kecil pelanggan memberikan kontribusi besar terhadap total penjualan
Fenomena ini sering dikenal sebagai prinsip Pareto (80/20), di mana sebagian kecil pelanggan berkontribusi terhadap sebagian besar pendapatan.


3) Outlier

Outlier adalah nilai yang jauh berbeda dari sebagian besar data lainnya. Keberadaan outlier dapat mempengaruhi hasil analisis, terutama pada perhitungan mean dan variance. Oleh karena itu, penting untuk mengidentifikasi outlier sebelum melakukan analisis lebih lanjut.



Gambar 1.7 Jenis Outliers

Interquartile Range (IQR) bisa digunakan untuk mendeteksi adanya outliers ini. Dengan IQR, dapat ditemukan sejumlah data yang berada di luar batas normal (outlier), misalnya nilai transaksi yang jauh lebih tinggi dibandingkan sebagian besar data lainnya. Outlier yang terdeteksi merupakan nilai transaksi yang berada di atas batas upper bound yang ditentukan oleh metode IQR. Nilai ini secara statistik dianggap sebagai data ekstrem.



Gambar 1.8 IQR untuk mendeteksi Outliers

Dalam dataset e-commerce, outlier tidak selalu merupakan kesalahan data. Nilai transaksi yang tinggi dapat mencerminkan:

- pembelian dalam jumlah besar
- pelanggan dengan daya beli tinggi
- transaksi khusus (bulk order)

Oleh karena itu, outlier perlu dianalisis lebih lanjut sebelum diputuskan untuk dihapus.

Statistical Analysis dengan Python

Dalam era modern, analisis statistik tidak hanya dilakukan secara manual, tetapi juga menggunakan perangkat lunak seperti Python. Python menyediakan berbagai pustaka yang memudahkan proses analisis data secara efisien dan sistematis.

Beberapa pustaka utama yang digunakan dalam analisis statistik antara lain:

- Pandas digunakan untuk membaca, mengelola, dan menganalisis data dalam bentuk tabel (DataFrame)
- NumPy digunakan untuk komputasi numerik dan operasi matematika
- Matplotlib digunakan untuk membuat visualisasi data seperti histogram dan grafik

Dengan menggunakan Python, proses perhitungan statistik deskriptif seperti mean, median, standar deviasi, serta analisis distribusi data dapat dilakukan dengan cepat dan akurat.

Selain itu, Python juga memungkinkan analisis untuk mengintegrasikan proses analisis data dengan visualisasi sehingga hasil analisis dapat lebih mudah dipahami.

3. Tujuan Praktikum

Setelah mengikuti kegiatan praktikum ini, mahasiswa diharapkan mampu:

- 1) Menghitung ukuran pemusatan data (mean, median, dan mode) menggunakan Python pada dataset transaksi e-commerce.
- 2) Menghitung ukuran penyebaran data (range, variance, dan standard deviation) untuk memahami tingkat variasi data.
- 3) Menghitung nilai quartile dan percentile sebagai dasar dalam memahami distribusi data.
- 4) Menganalisis distribusi data menggunakan pendekatan statistik deskriptif dan visualisasi histogram.
- 5) Mengidentifikasi keberadaan outlier menggunakan metode statistik seperti Interquartile Range (IQR).
- 6) Menginterpretasikan hasil analisis statistik untuk memahami karakteristik dan pola data transaksi e-commerce.
- 7) Mengaitkan hasil analisis statistik dengan implikasi bisnis dalam konteks transaksi e-commerce.

4. Langkah Praktikum

Pada praktikum ini, mahasiswa akan melakukan analisis statistik deskriptif terhadap dataset transaksi e-commerce yang telah diproses pada praktikum sebelumnya, dengan fokus pada atribut **payment_value** sebagai representasi nilai transaksi.

- 1) Mengimpor Library yang Dibutuhkan

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

Pada tahap ini dilakukan import pustaka Python yang akan digunakan selama proses analisis data, manipulasi data, serta visualisasi. Pustaka pandas digunakan untuk pengolahan data berbentuk tabel (DataFrame), numpy digunakan untuk komputasi numerik, dan matplotlib digunakan untuk visualisasi data. Pemilihan library yang tepat merupakan langkah awal dalam analisis data

- 2) Memuat Dataset

```
df = pd.read_csv("dataset/orders_processed.csv")
df.head()
```

Dataset yang digunakan merupakan bagian dari Brazilian E-Commerce Public Dataset by Olist, khususnya data transaksi pesanan yang telah melalui proses pembersihan pada praktikum sebelumnya. Dataset ini memuat informasi terkait transaksi pelanggan, termasuk nilai pembayaran (`payment_value`). Penggunaan dataset yang telah melalui tahap preprocessing sangat penting untuk memastikan bahwa analisis statistik yang dilakukan tidak terdistorsi oleh kesalahan data seperti missing values atau tipe data yang tidak sesuai.

Instruksi Analisis

Amati struktur data dan pastikan kolom **payment_value** tersedia sebagai atribut numerik yang akan dianalisis.

3) Menampilkan Statistik Deskriptif Awal

```
df.describe()
```

Fungsi `describe()` digunakan untuk menampilkan ringkasan statistik dari data numerik, meliputi nilai mean, standar deviasi, nilai minimum, maksimum, serta nilai quartile.

Instruksi Analisis

- Bandingkan nilai mean dan median
- Amati selisih antara nilai maksimum dan quartile

4) Menghitung Measures of Central Tendency

```
mean_val = df["payment_value"].mean()
median_val = df["payment_value"].median()
mode_val = df["payment_value"].mode()
```

```
mean_val, median_val, mode_val
```

Perhitungan dilakukan pada atribut `payment_value`, yang merepresentasikan nilai transaksi pada dataset e-commerce. Mean menunjukkan rata-rata nilai transaksi, median menunjukkan nilai tengah, sedangkan mode menunjukkan nilai yang paling sering muncul.

Instruksi Analisis

- Bandingkan mean dan median
- Tentukan apakah mean cukup representatif

5) Menghitung Measures of Variability

```
std_val = df["payment_value"].std()
var_val = df["payment_value"].var()
range_val = df["payment_value"].max() - df["payment_value"].min()
```

```
std_val, var_val, range_val
```

Ukuran penyebaran data dihitung untuk mengetahui tingkat variasi nilai transaksi. Standard deviation dan variance menunjukkan tingkat penyimpangan data terhadap rata-rata, sedangkan range menunjukkan selisih antara nilai maksimum dan minimum.

Instruksi Analisis

- Apakah nilai standar deviasi tinggi?
- Apa implikasinya terhadap variasi transaksi pelanggan?

6) Menghitung Quartile dan Percentile

```
quartiles = df["payment_value"].quantile([0.25, 0.5, 0.75])
quartiles
```

Perhitungan quartile digunakan untuk membagi data menjadi empat bagian yang sama besar. Nilai Q1, Q2 (median), dan Q3 memberikan informasi mengenai distribusi data. Quartile sering digunakan dalam analisis data untuk memahami penyebaran nilai serta sebagai dasar dalam mendeteksi outlier. Dalam konteks bisnis, nilai Q3 dapat digunakan untuk mengidentifikasi kelompok pelanggan dengan transaksi tinggi.

Instruksi Analisis

- Interpretasikan Q1, median, dan Q3
- Apakah terdapat jarak yang signifikan antar quartile?

7) Identifikasi Outlier Menggunakan Metode IQR

```
Q1 = df["payment_value"].quantile(0.25)
Q3 = df["payment_value"].quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

outliers = df[(df["payment_value"] < lower_bound) |
               (df["payment_value"] > upper_bound)]

outliers.shape
```

Metode Interquartile Range (IQR) digunakan untuk mengidentifikasi data yang berada di luar batas normal distribusi. Data yang berada di luar rentang tersebut dikategorikan sebagai outlier. Dalam analisis data e-commerce, outlier tidak selalu menunjukkan kesalahan data. Nilai transaksi yang sangat tinggi dapat merepresentasikan pelanggan dengan nilai pembelian besar (high-value customer). Oleh karena itu, identifikasi outlier harus diikuti dengan interpretasi yang tepat.

Instruksi Analisis

- Berapa jumlah outlier yang ditemukan?
- Apakah outlier perlu dihapus atau dianalisis lebih lanjut?

8) Visualisasi Distribusi Data (Histogram)

```
df["payment_value"].hist(bins=50)
plt.title("Distribusi Nilai Transaksi")
plt.xlabel("Payment Value")
plt.ylabel("Frekuensi")
plt.show()
```

Histogram digunakan untuk memvisualisasikan distribusi nilai transaksi. Grafik ini menunjukkan frekuensi kemunculan nilai dalam rentang tertentu.

Distribusi data transaksi e-commerce umumnya tidak simetris dan cenderung miring ke kanan. Hal ini menunjukkan bahwa sebagian besar pelanggan melakukan transaksi dengan nilai kecil, sementara hanya sebagian kecil yang memiliki nilai transaksi tinggi.

Instruksi Analisis

- Apakah distribusi data simetris?
- Apakah data cenderung skewed ke kiri atau ke kanan?

5. Hasil dan Pembahasan

Pada praktikum ini dilakukan analisis statistik deskriptif terhadap atribut **payment_value** pada dataset transaksi e-commerce yang berasal dari Brazilian E-Commerce Public Dataset by Olist. Analisis ini bertujuan untuk memahami karakteristik data transaksi serta mengidentifikasi pola yang terdapat dalam dataset.

1) Statistik Deskriptif Awal

Berdasarkan hasil eksekusi fungsi `describe()`, diperoleh informasi mengenai nilai rata-rata (mean), standar deviasi, nilai minimum, maksimum, serta distribusi quartile dari data transaksi. Hasil menunjukkan bahwa nilai maksimum transaksi jauh lebih besar dibandingkan nilai median dan quartile atas (Q3). Selain itu, terdapat perbedaan antara nilai mean dan median. Hal ini mengindikasikan bahwa distribusi data tidak simetris dan cenderung dipengaruhi oleh nilai transaksi yang tinggi.

Implikasi Analitis

Perbedaan antara mean dan median menunjukkan adanya distribusi data yang tidak normal, sehingga penggunaan mean sebagai representasi nilai transaksi perlu dilakukan dengan hati-hati.

2) Analisis Measures of Central Tendency

Hasil perhitungan menunjukkan bahwa:

- nilai mean lebih besar dibandingkan median
- median berada pada nilai yang lebih rendah
- mode menunjukkan nilai transaksi yang paling sering terjadi

Perbedaan antara mean dan median menunjukkan bahwa distribusi data cenderung miring ke kanan (positively skewed). Hal ini disebabkan oleh adanya sejumlah transaksi dengan nilai yang sangat tinggi. Median lebih mencerminkan nilai transaksi yang umum terjadi karena tidak dipengaruhi oleh nilai ekstrem.

Implikasi Analitis

Dalam analisis data transaksi e-commerce, median lebih tepat digunakan sebagai ukuran representatif untuk menggambarkan perilaku mayoritas pelanggan dibandingkan mean.

3) Analisis Measures of Variability

Hasil perhitungan menunjukkan bahwa nilai standar deviasi relatif tinggi dan range data cukup besar.

Nilai standar deviasi yang tinggi menunjukkan bahwa data memiliki variasi yang signifikan. Hal ini berarti nilai transaksi pelanggan tidak homogen dan tersebar dalam rentang yang luas. Range yang besar juga mengindikasikan adanya perbedaan yang signifikan antara transaksi dengan nilai rendah dan tinggi.

Implikasi Analitis

Variabilitas yang tinggi menunjukkan adanya perbedaan karakteristik pelanggan, yang dapat mengindikasikan adanya segmentasi pelanggan berdasarkan nilai transaksi.

4) Analisis Quartile dan Percentile

Berdasarkan hasil perhitungan quartile, diketahui bahwa sebagian besar data berada dalam rentang antara Q1 dan Q3, sementara nilai maksimum berada jauh di atas Q3.

Distribusi ini menunjukkan bahwa terdapat sejumlah kecil data yang berada di luar distribusi utama, yang dapat dikategorikan sebagai nilai ekstrem.

Implikasi Analitis

Nilai Q3 dapat digunakan sebagai batas untuk mengidentifikasi kelompok pelanggan dengan nilai transaksi tinggi, yang memiliki kontribusi signifikan terhadap total penjualan.

5) Identifikasi Outlier

Berdasarkan metode Interquartile Range (IQR), ditemukan sejumlah data yang berada di luar batas normal distribusi.

Outlier merupakan data yang memiliki nilai jauh di atas atau di bawah rentang normal. Dalam dataset ini, outlier cenderung berada pada nilai transaksi yang sangat tinggi.

Implikasi Analitis

Dalam konteks e-commerce, outlier tidak selalu merupakan kesalahan data. Nilai transaksi yang tinggi dapat mencerminkan pelanggan dengan daya beli tinggi atau transaksi dalam jumlah besar. Oleh karena itu, outlier perlu dianalisis lebih lanjut sebelum dilakukan penghapusan.

6) Analisis Distribusi Data

Berdasarkan hasil visualisasi histogram, distribusi data menunjukkan pola yang tidak simetris dan cenderung miring ke kanan. Distribusi yang miring ke kanan menunjukkan bahwa sebagian besar pelanggan melakukan transaksi dengan nilai rendah, sedangkan hanya sebagian kecil pelanggan yang melakukan transaksi dengan nilai tinggi.

Implikasi Analitis

Pola distribusi ini umum terjadi dalam data transaksi e-commerce, di mana sebagian besar pendapatan dapat berasal dari sebagian kecil pelanggan.

6. Soal Praktikum

Mahasiswa diminta untuk menjawab pertanyaan berikut berdasarkan hasil analisis yang dilakukan menggunakan dataset yang dipilih secara mandiri, dengan karakteristik yang serupa dengan dataset transaksi e-commerce pada modul. Setelah itu jawablah pertanyaan di bawah ini.

A. Pemahaman Konsep dan Analisis

- 1) Jelaskan perbedaan antara mean, median, dan mode. Dalam kondisi seperti apa median lebih tepat digunakan dibandingkan mean?
- 2) Berdasarkan hasil analisis pada dataset yang Anda gunakan, apakah nilai mean dapat merepresentasikan data dengan baik? Jelaskan alasan Anda.
- 3) Apa yang dimaksud dengan standard deviation? Bagaimana interpretasi nilai tersebut pada dataset yang Anda analisis?
- 4) Jelaskan fungsi quartile dalam analisis data. Apa informasi yang dapat diperoleh dari nilai Q1, Q2, dan Q3 pada dataset Anda?

B. Analisis Data

- 1) Berdasarkan histogram yang dihasilkan, bagaimana bentuk distribusi data Anda? Apakah data berdistribusi normal atau skewed? Jelaskan.
- 2) Apakah terdapat outlier dalam dataset Anda? Jelaskan metode yang digunakan untuk mengidentifikasinya serta hasil yang diperoleh.
- 3) Bandingkan nilai mean dan median pada variabel numerik yang Anda analisis. Apa yang dapat disimpulkan mengenai karakteristik data tersebut?

C. Interpretasi dan Implikasi

- 1) Apa yang dapat disimpulkan mengenai pola data berdasarkan hasil analisis statistik yang dilakukan?
- 2) Bagaimana hubungan antara variasi data (standard deviation) dengan karakteristik data pada dataset Anda?
- 3) Jelaskan implikasi dari hasil analisis statistik terhadap konteks dataset yang digunakan.

7. Tugas Laporan

Mahasiswa diminta menyusun laporan praktikum berdasarkan hasil analisis yang dilakukan menggunakan dataset pilihan masing-masing.

Dataset yang digunakan harus memiliki karakteristik yang memungkinkan penerapan statistik deskriptif dan analisis distribusi data.

Ketentuan Dataset

Dataset yang digunakan harus memenuhi kriteria berikut:

- Memiliki minimal 1 variabel numerik utama
- Memiliki jumlah data minimal 100 baris
- Memiliki variasi data yang cukup (tidak homogen)
- Memiliki konteks yang jelas (misalnya: transaksi, penjualan, nilai, skor, dll.)

Dataset yang terlalu sederhana atau tidak memungkinkan analisis distribusi data tidak diperbolehkan.

Struktur Laporan

Laporan harus memuat bagian berikut:

- 1) Judul Praktikum
- 2) Tujuan Praktikum
- 3) Dasar Teori
- 4) Deskripsi Dataset
- 5) Langkah Praktikum
- 6) Hasil dan Pembahasan
- 7) Kesimpulan
- 8) Daftar Pustaka
- 9) Lampiran

Ketentuan Isi Laporan

Mahasiswa wajib:

- Menjelaskan dataset yang digunakan (sumber, jumlah data, variabel)
- Menampilkan hasil perhitungan:
 - mean, median, mode
 - variance, standard deviation, range
- Menampilkan hasil quartile dan analisis distribusi
- Menyajikan visualisasi histogram
- Mengidentifikasi dan menjelaskan outlier
- Memberikan interpretasi hasil analisis
- Mengaitkan hasil analisis dengan konteks dataset

Lampiran Wajib

Screenshot hasil describe()

Screenshot perhitungan statistik deskriptif

Screenshot quartile

Screenshot histogram

Screenshot identifikasi outlier

Kode program Python

Ketentuan Penilaian

Penilaian laporan didasarkan pada:

- Pemahaman konsep
- Ketepatan analisis
- Implementasi tools
- Kualitas interpretasi
- Kerapian laporan