

MODUL 2

EXPLORATORY DATA ANALYSIS (EDA)

LAB 4. Exploratory Data Analysis

1. CPMK dan SubCPMK

CPMK-1018 - Mampu melakukan exploratory data analysis (EDA) dan menerapkan statistik deskriptif untuk analisis data.

Sub-CPMK

Mahasiswa mampu memahami dan menerapkan konsep EDA dalam analisis data.

Indikator capaian pada SubCPMK ini adalah mahasiswa memiliki kemampuan untuk:

- melakukan univariate analysis untuk memahami karakteristik variabel
- melakukan bivariate analysis untuk mengidentifikasi hubungan antar variabel
- melakukan correlation analysis untuk mengukur kekuatan hubungan
- mengidentifikasi pola (patterns) dalam data
- mengidentifikasi outliers dan anomalies
- menginterpretasikan hasil EDA secara analitis
- mengaitkan hasil EDA dengan konteks bisnis

Kata kunci penting: eksplorasi, hubungan, pola, interpretasi

2. Dasar Teori

Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan proses awal dalam analisis data yang bertujuan untuk memahami struktur, karakteristik, distribusi, serta hubungan antar variabel dalam suatu dataset. EDA dilakukan sebelum analisis lanjutan seperti pemodelan statistik atau machine learning, dengan tujuan untuk memastikan bahwa data yang digunakan

telah dipahami secara menyeluruh dan tidak mengandung kesalahan yang dapat mempengaruhi hasil analisis.

Dalam praktiknya, EDA melibatkan kombinasi antara analisis statistik deskriptif dan visualisasi data. Namun, berbeda dengan statistik deskriptif yang hanya berfokus pada perhitungan nilai-nilai ringkasan seperti mean dan standar deviasi, EDA lebih menekankan pada eksplorasi data secara menyeluruh untuk menemukan pola (patterns), hubungan (relationships), serta anomali (anomalies) yang mungkin tidak terlihat secara langsung.

EDA memiliki peran yang sangat penting dalam pipeline analisis data karena kesalahan dalam memahami data pada tahap awal dapat menyebabkan kesalahan interpretasi yang berdampak pada pengambilan keputusan. Data yang tidak dianalisis secara eksploratif berpotensi mengandung bias, distribusi yang tidak normal, atau outlier yang dapat mempengaruhi hasil analisis lanjutan.

Berbeda dengan statistik deskriptif yang berfokus pada perhitungan ringkasan data seperti mean dan standar deviasi, EDA lebih menekankan pada proses eksplorasi untuk menjawab pertanyaan seperti:

- bagaimana distribusi data,
- apakah terdapat hubungan antar variabel,
- apakah terdapat pola tertentu,
- dan apakah terdapat nilai yang tidak wajar (anomali atau outlier).

EDA membantu analis dalam memahami data secara lebih mendalam sehingga dapat menghindari kesalahan dalam interpretasi maupun pengambilan keputusan.

Contohnya pada dataset transaksi e-commerce, seorang analis ingin mengetahui rata-rata nilai transaksi pelanggan. Jika analis hanya melihat nilai mean, maka hasil yang diperoleh mungkin menunjukkan nilai transaksi yang relatif tinggi. Namun, setelah dilakukan EDA, ditemukan bahwa distribusi data sangat miring ke kanan (positively skewed), di mana sebagian besar pelanggan melakukan transaksi kecil, sementara hanya sebagian kecil pelanggan melakukan transaksi dengan nilai yang sangat besar.

Implikasi Analitis:


Tanpa EDA, penggunaan mean sebagai representasi nilai transaksi dapat menyesatkan karena dipengaruhi oleh nilai ekstrem. Dengan EDA, analisis dapat memahami bahwa median lebih representatif dalam menggambarkan perilaku mayoritas pelanggan.

Penting dalam Dunia Bisnis:

- Menghindari kesalahan dalam interpretasi data
- Menjadi dasar dalam pengambilan keputusan berbasis data
- Membantu memahami perilaku pelanggan secara lebih akurat
- Mengurangi risiko keputusan yang bias atau tidak tepat

Univariate Analysis (Analisis Satu Variabel)

Univariate analysis adalah teknik analisis data yang berfokus pada satu variabel untuk memahami distribusi, pusat data, serta penyebaran nilai dalam dataset. Analisis ini merupakan langkah awal dalam EDA karena memberikan gambaran dasar mengenai karakteristik setiap variabel sebelum dilakukan analisis yang lebih kompleks.



Gambar 2.1 Visualisasi Distribusi Data

Dalam univariate analysis, analis akan mengamati bagaimana data tersebar, apakah data memiliki distribusi normal atau tidak, serta apakah terdapat nilai ekstrem (outlier) yang dapat mempengaruhi analisis. Pemahaman terhadap distribusi data sangat penting karena akan menentukan metode analisis yang digunakan pada tahap selanjutnya. Analisis ini membantu menjawab pertanyaan: “Seperti apa karakteristik data ini?”

Jadi untuk analisis univariate menggunakan visualisasi berupa histogram yang digunakan untuk melihat bentuk distribusi data, sedangkan boxplot digunakan untuk mengidentifikasi median, quartile, dan outlier dalam dataset, seperti yang ditunjukkan pada Gambar 2.1.

Pada Gambar 2.1 nilai transaksi pelanggan digambarkan:

- Sebagian besar nilai transaksi berada pada rentang rendah
- Terdapat beberapa transaksi dengan nilai yang sangat tinggi

Distribusi seperti ini disebut sebagai **right-skewed distribution**, di mana ekor distribusi memanjang ke arah kanan.

Implikasi Analitis:

Distribusi yang tidak simetris menunjukkan bahwa data tidak homogen dan memiliki variasi yang tinggi. Dalam kondisi ini, penggunaan mean sebagai ukuran pusat data dapat menjadi tidak representatif, sehingga median lebih tepat digunakan.


Penting dalam Dunia Bisnis:

- Membantu memahami perilaku mayoritas pelanggan
- Menentukan strategi harga dan segmentasi pasar
- Mengidentifikasi distribusi nilai transaksi
- Menjadi dasar dalam analisis lanjutan

Bivariate Analysis (Analisis Dua Variabel)

Bivariate analysis merupakan teknik analisis yang digunakan untuk memahami hubungan antara dua variabel dalam dataset. Analisis ini bertujuan untuk mengidentifikasi apakah terdapat hubungan atau keterkaitan antara perubahan satu variabel terhadap variabel lainnya.

Dalam bivariate analysis, hubungan antar variabel dapat bersifat positif, negatif, atau tidak memiliki hubungan sama sekali. Analisis ini sangat penting dalam memahami faktor-faktor yang mempengaruhi suatu fenomena dalam data. Analisis ini menjawab pertanyaan: **“Apakah perubahan satu variabel mempengaruhi variabel lain?”**



Gambar 2.2 Visualisasi Hubungan Antar Variabel

Scatter plot digunakan untuk memvisualisasikan hubungan antara dua variabel numerik. Pola titik pada grafik menunjukkan arah dan kekuatan hubungan antar variabel.

Contoh Kasus:

Pada dataset e-commerce:

- Variabel X: jumlah produk yang dibeli
- Variabel Y: nilai transaksi

Hasil analisis menunjukkan bahwa semakin banyak produk yang dibeli, maka nilai transaksi cenderung meningkat.

Implikasi Analitis:

Hubungan positif antara jumlah produk dan nilai transaksi menunjukkan bahwa strategi upselling dapat meningkatkan pendapatan.

Penting dalam Dunia Bisnis:

- Mengidentifikasi faktor yang mempengaruhi penjualan
- Menentukan strategi pemasaran
- Mengoptimalkan penawaran produk
- Mendukung pengambilan keputusan berbasis data


Correlation Analysis (Analisis Korelasi)

Correlation analysis merupakan metode statistik yang digunakan untuk mengukur kekuatan dan arah hubungan antara dua variabel numerik. Korelasi dinyatakan dalam bentuk koefisien yang memiliki nilai antara -1 hingga +1.

Nilai korelasi menunjukkan:

- +1 → hubungan positif sempurna
- 0 → tidak ada hubungan
- -1 → hubungan negatif sempurna

Korelasi digunakan untuk mengukur hubungan antar variabel dalam dataset.



Gambar 2.3 Visualisasi Korelasi

Heatmap digunakan untuk memvisualisasikan hubungan antar banyak variabel secara simultan.

Contoh Kasus:

- Korelasi antara diskon dan jumlah pembelian
- Korelasi antara rating produk dan jumlah penjualan

Jika nilai korelasi tinggi, maka kedua variabel memiliki hubungan yang kuat.

Implikasi Analitis:


Korelasi yang tinggi dapat menunjukkan bahwa suatu variabel memiliki pengaruh signifikan terhadap variabel lainnya. Namun, penting untuk diingat bahwa korelasi tidak selalu menunjukkan hubungan sebab-akibat.

Penting dalam Dunia Bisnis:

- Menentukan faktor utama yang mempengaruhi performa bisnis
- Membantu dalam pemilihan variabel untuk model prediksi
- Menghindari redundansi data
- Mendukung analisis strategis

Identifying Patterns (Pola Data)

Pola data merupakan kecenderungan atau struktur tertentu yang muncul dalam dataset, seperti tren, segmentasi, atau kelompok data (cluster). Identifikasi pola merupakan bagian penting dari EDA karena dapat memberikan insight mengenai perilaku data dalam jangka waktu tertentu atau dalam kondisi tertentu.



Gambar 2.4 Visualisasi Pola

Contoh Kasus:

- Penjualan meningkat pada akhir bulan
- Terdapat kelompok pelanggan dengan nilai transaksi tinggi


Implikasi Analitis:

Pola yang ditemukan dapat digunakan untuk memprediksi perilaku di masa depan serta membantu dalam pengambilan keputusan strategis.

- Penting dalam Dunia Bisnis:
- Identifikasi tren pasar
- Segmentasi pelanggan
- Perencanaan strategi pemasaran
- Prediksi permintaan

Identifying Outliers dan Anomalies

Outlier adalah nilai data yang secara signifikan berbeda dari sebagian besar data lainnya. Keberadaan outlier dapat disebabkan oleh kesalahan data atau fenomena khusus yang memiliki nilai penting dalam analisis.



Gambar 2.5 Visualisasi Outlier

Outlier dapat diidentifikasi menggunakan metode statistik seperti Interquartile Range (IQR), di mana data yang berada di luar batas normal dikategorikan sebagai outlier. Outlier merupakan nilai ekstrem yang dapat mempengaruhi hasil analisis.

Contoh Kasus dalam dataset transaksi:

- Sebagian besar transaksi < 500
- Terdapat transaksi > 10.000

Implikasi Analitis:

Nilai ekstrem tersebut dapat menunjukkan:

- pelanggan dengan daya beli tinggi
- transaksi dalam jumlah besar
- atau kesalahan data

Penting dalam Dunia Bisnis:

- Deteksi fraud
- Identifikasi pelanggan premium
- Evaluasi performa bisnis
- Pengambilan keputusan berbasis data

Insight dan Interpretasi Data

Tahap akhir dari EDA adalah interpretasi data, yaitu proses mengubah hasil analisis menjadi insight yang dapat digunakan untuk pengambilan keputusan.

Interpretasi data tidak hanya menjelaskan apa yang terjadi dalam data, tetapi juga mengapa hal tersebut terjadi dan bagaimana dampaknya terhadap bisnis.

Contoh:

- Mean > median → distribusi tidak normal
- Korelasi tinggi → variabel saling berhubungan
- Outlier → segmen khusus pelanggan

Penting dalam Dunia Bisnis:

- Mengubah data menjadi informasi yang actionable
- Mendukung pengambilan keputusan strategis
- Memberikan nilai tambah dari analisis data

3. Tujuan Praktikum

Setelah mengikuti praktikum ini, mahasiswa mampu:

- Melakukan analisis univariate untuk memahami distribusi data
- Melakukan analisis bivariate untuk melihat hubungan antar variabel
- Menghitung dan menginterpretasikan korelasi antar variabel
- Mengidentifikasi pola (patterns) dalam dataset
- Mengidentifikasi outlier dan anomali dalam data
- Menggunakan visualisasi untuk mendukung analisis EDA
- Menginterpretasikan hasil EDA dalam konteks dataset
- Mengaitkan hasil analisis dengan implikasi bisnis

4. Langkah Praktikum

Pada praktikum ini, mahasiswa akan melakukan Exploratory Data Analysis (EDA) terhadap dataset yang telah diproses sebelumnya. Fokus utama adalah memahami distribusi data, hubungan antar variabel, serta mengidentifikasi pola dan anomali yang terdapat dalam dataset.

Dataset yang digunakan dapat berasal dari praktikum sebelumnya atau dataset lain dengan karakteristik serupa (memiliki variabel numerik dan kategorikal).

1) Mengimpor Library yang Dibutuhkan

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_style("whitegrid")
```

Pada tahap ini dilakukan import pustaka yang digunakan untuk manipulasi data dan visualisasi.

Pandas digunakan untuk pengolahan data, NumPy untuk komputasi numerik, serta Matplotlib dan Seaborn untuk visualisasi data.

Instruksi Analisis:

- Mengapa visualisasi penting dalam EDA?
- Apa perbedaan matplotlib dan seaborn dalam konteks analisis data?

2) Memuat Dataset

```
df = pd.read_csv("dataset/orders_processed.csv")
df.head()
```

Dataset yang digunakan merupakan dataset transaksi e-commerce yang telah melalui tahap preprocessing sebelumnya.

Instruksi Analisis:

- Identifikasi jumlah baris dan kolom
- Tentukan tipe data setiap variabel
- Pilih minimal 2 variabel numerik dan 1 variabel kategorikal untuk analisis

3) Memahami Struktur Data

```
df.info()
df.describe()
```

Fungsi `info()` digunakan untuk melihat struktur data, sedangkan `describe()` digunakan untuk melihat statistik deskriptif awal.

Instruksi Analisis:

- Apakah terdapat missing values?
- Apakah terdapat perbedaan signifikan antara mean dan median?
- Apa indikasi awal distribusi data?

4) Univariate Analysis (Distribusi Data)

```
plt.figure(figsize=(8,5))
df["payment_value"].hist(bins=50)
plt.title("Distribusi Nilai Transaksi")
plt.xlabel("Payment Value")
plt.ylabel("Frekuensi")
plt.show()
```

Histogram digunakan untuk melihat distribusi data.

```
sns.boxplot(x=df["payment_value"])
plt.title("Boxplot Nilai Transaksi")
plt.show()
```

Boxplot digunakan untuk mendeteksi outlier.

Instruksi Analisis:

- Apakah distribusi data simetris atau skewed?
- Apakah terdapat outlier?
- Mana yang lebih representatif: mean atau median?

5) Bivariate Analysis (Hubungan Antar Variabel)

```
sns.scatterplot(x="payment_value", y="freight_value",
data=df)
plt.title("Hubungan Payment Value dan Freight Value")
plt.show()
```

Scatter plot digunakan untuk melihat hubungan antara dua variabel numerik.

```
sns.boxplot(x="payment_type", y="payment_value", data=df)
plt.xticks(rotation=45)
plt.show()
```

Digunakan untuk melihat perbedaan distribusi antar kategori.

Instruksi Analisis:

- Apakah terdapat hubungan antar variabel?
- Variabel mana yang tampak berpengaruh?
- Apakah ada perbedaan signifikan antar kategori?

6) Correlation Analysis

```
corr = df.select_dtypes(include=np.number).corr()

plt.figure(figsize=(10,6))
sns.heatmap(corr, annot=True, cmap="coolwarm")
plt.title("Correlation Heatmap")
plt.show()
```

Heatmap digunakan untuk melihat hubungan antar variabel numerik secara keseluruhan.

Instruksi Analisis:

- Variabel mana yang memiliki korelasi tinggi?
- Apakah terdapat korelasi negatif?
- Apakah semua variabel penting?

7) Identifikasi Outlier (Metode IQR)

```
Q1 = df["payment_value"].quantile(0.25)
Q3 = df["payment_value"].quantile(0.75)
IQR = Q3 - Q1
```

```
lower_bound = Q1 - 1.5 * IQR
```

```
upper_bound = Q3 + 1.5 * IQR

outliers = df[(df["payment_value"] < lower_bound) |
              (df["payment_value"] > upper_bound)]

outliers.shape
```

Metode IQR digunakan untuk mendeteksi outlier secara statistik.

Instruksi Analisis:

- Berapa jumlah outlier?
- Apakah outlier perlu dihapus?
- Apakah outlier memiliki makna bisnis?

8) Identifikasi Pola (Patterns)

```
df.groupby("order_purchase_timestamp")["payment_value"].
sum().plot()
plt.title("Trend Transaksi")
plt.show()
```

Digunakan untuk melihat pola tren dalam data.

Instruksi Analisis:

- Apakah terdapat tren naik atau turun?
- Apakah ada pola tertentu?
- Apa kemungkinan penyebab pola tersebut?

9) Menarik Insight (Interpretasi Data)

Mahasiswa diminta menyimpulkan hasil EDA:

Instruksi Analisis:

- Apa pola utama dalam data?
- Variabel apa yang paling berpengaruh?
- Apakah terdapat anomali penting?
- Apa implikasi bisnis dari hasil analisis?

5. Hasil dan Pembahasan

Pada praktikum ini dilakukan Exploratory Data Analysis (EDA) terhadap dataset transaksi e-commerce dengan tujuan untuk memahami

karakteristik data, hubungan antar variabel, serta mengidentifikasi pola dan anomali yang terdapat dalam dataset.

1) Pemahaman Awal Dataset

Berdasarkan hasil eksplorasi awal menggunakan fungsi `info()` dan `describe()`, diperoleh informasi mengenai struktur dataset, tipe data, serta statistik deskriptif awal.

Hasil menunjukkan bahwa:

- dataset terdiri dari variabel numerik dan kategorikal
- variabel numerik seperti `payment_value` memiliki rentang nilai yang cukup besar
- terdapat perbedaan antara nilai mean dan median

Implikasi Analitis:

Perbedaan antara mean dan median mengindikasikan bahwa distribusi data tidak simetris dan kemungkinan terdapat nilai ekstrem (outlier) yang mempengaruhi rata-rata.

2) Analisis Univariate (Distribusi Data)

Berdasarkan visualisasi histogram dan boxplot, distribusi data menunjukkan pola yang tidak simetris dan cenderung miring ke kanan (positively skewed).

Interpretasi:

- Sebagian besar data berada pada nilai rendah
- Terdapat sejumlah kecil data dengan nilai sangat tinggi

Implikasi Analitis:

Distribusi yang skewed menunjukkan bahwa data tidak homogen dan memiliki variasi yang tinggi. Dalam kondisi ini, median lebih representatif dibandingkan mean untuk menggambarkan nilai pusat data.

Implikasi Bisnis:

- Mayoritas pelanggan melakukan transaksi dengan nilai kecil
- Sebagian kecil pelanggan memberikan kontribusi besar terhadap pendapatan
- Fenomena ini sesuai dengan prinsip Pareto (80/20)

3) Analisis Bivariate (Hubungan Antar Variabel)

Berdasarkan scatter plot antara payment_value dan variabel lain (misalnya freight_value), terlihat adanya kecenderungan hubungan tertentu.

Interpretasi:

- Jika pola titik menunjukkan arah naik → hubungan positif
- Jika tidak membentuk pola → tidak ada hubungan yang jelas

Implikasi Analitis:

Hubungan antar variabel menunjukkan adanya keterkaitan yang dapat digunakan untuk memahami faktor-faktor yang mempengaruhi nilai transaksi.

Implikasi Bisnis:

- Jika hubungan positif → peluang untuk meningkatkan penjualan melalui variabel terkait
- Jika tidak ada hubungan → variabel tersebut kurang relevan dalam strategi bisnis

4) Analisis Korelasi

Berdasarkan heatmap korelasi, diperoleh nilai korelasi antar variabel numerik.

Interpretasi:

- Nilai mendekati +1 → hubungan positif kuat
- Nilai mendekati 0 → tidak ada hubungan
- Nilai mendekati -1 → hubungan negatif

Implikasi Analitis:

Variabel dengan korelasi tinggi menunjukkan adanya hubungan yang signifikan dan dapat digunakan dalam analisis lanjutan.

Implikasi Bisnis:

- Menentukan variabel yang paling berpengaruh terhadap performa bisnis
- Menghindari penggunaan variabel yang tidak relevan

5) Identifikasi Outlier

Berdasarkan metode Interquartile Range (IQR), ditemukan sejumlah data yang berada di luar batas normal distribusi.

Interpretasi:

- Outlier berada jauh di atas nilai mayoritas data
- Nilai ini tergolong ekstrem dibandingkan distribusi utama

Implikasi Analitis:

Outlier dapat mempengaruhi hasil analisis, terutama dalam perhitungan mean dan variance.

Implikasi Bisnis:

Outlier tidak selalu merupakan kesalahan data. Dalam konteks e-commerce, outlier dapat menunjukkan:

- pelanggan dengan nilai transaksi tinggi (high-value customer)
- pembelian dalam jumlah besar
- transaksi khusus

Sehingga outlier perlu dianalisis lebih lanjut sebelum diputuskan untuk dihapus.

6) Identifikasi Pola (Patterns)

Berdasarkan analisis tren dan agregasi data, ditemukan pola tertentu dalam dataset.

Interpretasi:

- Terdapat tren kenaikan atau penurunan
- Kemungkinan adanya pola periodik atau musiman

Implikasi Analitis:

Pola yang ditemukan menunjukkan adanya perilaku tertentu dalam data yang dapat digunakan untuk analisis lebih lanjut.

Implikasi Bisnis:

- Menentukan waktu terbaik untuk promosi
- Memahami perilaku pelanggan
- Mendukung strategi penjualan

7) Insight dan Kesimpulan Analitis

Berdasarkan keseluruhan hasil EDA, dapat disimpulkan bahwa:

- Data memiliki distribusi yang tidak normal (skewed)
- Terdapat hubungan antar beberapa variabel
- Ditemukan outlier yang signifikan

- Terdapat pola tertentu dalam data

Insight Utama:

- Sebagian kecil pelanggan memberikan kontribusi besar terhadap pendapatan
- Variabel tertentu memiliki pengaruh terhadap nilai transaksi
- Data memiliki variasi yang tinggi

Implikasi Bisnis:

- Fokus pada pelanggan high-value
- Optimalisasi strategi pemasaran
- Pengambilan keputusan berbasis data

6. Soal Praktikum

Mahasiswa diminta untuk menjawab pertanyaan berikut berdasarkan hasil Exploratory Data Analysis (EDA) yang telah dilakukan menggunakan dataset masing-masing yang memiliki karakteristik serupa dengan dataset pada modul.

A. Pemahaman Konsep dan Analisis

1. Jelaskan apa yang dimaksud dengan Exploratory Data Analysis (EDA). Apa perbedaan utama antara EDA dan statistik deskriptif?
2. Mengapa tahap EDA penting sebelum melakukan analisis lanjutan seperti machine learning atau modeling?
3. Apa yang dimaksud dengan univariate dan bivariate analysis? Berikan contoh penerapannya pada dataset Anda.
4. Jelaskan konsep korelasi. Apakah korelasi selalu menunjukkan hubungan sebab-akibat? Berikan alasan.

B. Analisis Data

1. Berdasarkan hasil univariate analysis:
 - Bagaimana bentuk distribusi data Anda?
 - Apakah data berdistribusi normal atau skewed?
 - Apa implikasinya terhadap penggunaan mean atau median?
2. Berdasarkan hasil bivariate analysis:
 - Apakah terdapat hubungan antar variabel?
 - Variabel mana yang paling terlihat memiliki hubungan?
 - Jelaskan pola hubungan tersebut.
3. Berdasarkan correlation analysis:
 - Variabel mana yang memiliki korelasi paling tinggi?
 - Apakah terdapat korelasi negatif?

- Apa arti dari hasil tersebut?
- 4. Apakah terdapat outlier dalam dataset Anda?
 - Metode apa yang digunakan untuk mendeteksi outlier?
 - Berapa jumlah outlier yang ditemukan?
- 5. Berdasarkan analisis pola (patterns):
 - Apakah terdapat tren atau pola tertentu dalam data?
 - Jelaskan pola yang ditemukan.

C. Interpretasi dan Implikasi

1. Apa insight utama yang Anda temukan dari hasil EDA?
2. Variabel apa yang paling berpengaruh dalam dataset Anda? Jelaskan alasan Anda.
3. Bagaimana hubungan antara distribusi data, korelasi, dan outlier dalam dataset Anda?
4. Apakah terdapat anomali yang menarik dalam data Anda? Jelaskan.
5. Apa implikasi dari hasil analisis tersebut terhadap konteks dataset yang Anda gunakan?

D. Critical Thinking

1. Jika Anda hanya melihat mean tanpa melakukan EDA, kesalahan apa yang mungkin terjadi?
2. Apakah semua outlier harus dihapus? Jelaskan dengan konteks dataset Anda.
3. Jika ditemukan korelasi tinggi antara dua variabel, apa langkah selanjutnya yang seharusnya dilakukan?

7. Tugas Laporan

Mahasiswa diminta menyusun laporan praktikum berdasarkan hasil Exploratory Data Analysis (EDA) yang dilakukan menggunakan dataset pilihan masing-masing.

Dataset yang digunakan harus memiliki karakteristik yang memungkinkan dilakukan analisis EDA secara menyeluruh.

Ketentuan Dataset

Dataset yang digunakan harus memenuhi kriteria berikut:

- Memiliki minimal:
 - o 2 variabel numerik
 - o 1 variabel kategorikal
- Memiliki minimal 100 baris data

- Memiliki variasi data (tidak homogen)
- Memiliki konteks yang jelas (misalnya: transaksi, penjualan, pelanggan, nilai, dll.)

Dataset yang terlalu sederhana atau tidak memungkinkan analisis hubungan antar variabel tidak diperbolehkan.

Struktur Laporan

Laporan harus memuat bagian berikut:

1. Judul Praktikum
2. Tujuan Praktikum
3. Dasar Teori
4. Deskripsi Dataset
5. Langkah Praktikum
6. Hasil dan Pembahasan
7. Kesimpulan
8. Daftar Pustaka
9. Lampiran

Ketentuan Isi Laporan

Mahasiswa wajib:

A. Deskripsi Dataset

Menjelaskan sumber dataset

Menjelaskan jumlah data dan variabel

Menjelaskan konteks data

B. Analisis EDA

Menampilkan dan menjelaskan:

1. Univariate Analysis
 - Distribusi data (histogram)
 - Identifikasi skewness
 - Interpretasi
2. Bivariate Analysis
 - Scatter plot atau boxplot
 - Interpretasi hubungan antar variabel
3. Correlation Analysis
 - Heatmap korelasi
 - Interpretasi nilai korelasi
4. Outlier Detection

- Metode IQR
 - Jumlah outlier
 - Interpretasi
5. Identifikasi Pola
- Tren atau pola data
 - Interpretasi

C. Interpretasi dan Insight

Mahasiswa wajib:

- Menjelaskan hasil analisis
- Menarik insight dari data
- Mengaitkan hasil dengan konteks dataset

Lampiran Wajib

- Screenshot df.info()
- Screenshot df.describe()
- Histogram
- Scatter plot / boxplot
- Heatmap korelasi
- Hasil identifikasi outlier
- Kode program Python

Ketentuan Penilaian

- Pemahaman konsep EDA
- Ketepatan analisis
- Kemampuan interpretasi
- Kualitas insight
- Keterkaitan dengan konteks bisnis
- Kerapian laporan

Rubrik Penilaian Laporan Praktikum EDA

Total nilai: 100 poin

A. Pemahaman Konsep EDA (15 poin)

Kriteria	Skor
Tidak mampu menjelaskan konsep EDA, hanya copy teori	0-5
Menjelaskan konsep tapi masih umum dan tidak tepat	6-10
Menjelaskan konsep dengan benar dan relevan dengan praktikum	11-15

B. Deskripsi Dataset (10 poin)

Kriteria	Skor
Tidak menjelaskan dataset	0-3
Menjelaskan sebagian (tanpa konteks)	4-7
Menjelaskan lengkap (sumber, variabel, konteks)	8-10

C. Univariate Analysis (15 poin)

Kriteria	Skor
Hanya menampilkan grafik tanpa penjelasan	0-5
Ada penjelasan tapi dangkal	6-10
Analisis lengkap + interpretasi distribusi + insight	11-15

D. Bivariate Analysis (15 poin)

Kriteria	Skor
Tidak ada analisis hubungan	0-5
Ada grafik tapi tidak jelas hubungan	6-10
Menjelaskan hubungan + pola + interpretasi	11-15

E. Correlation Analysis (10 poin)

Kriteria	Skor
Tidak ada analisis korelasi	0-3
Menampilkan heatmap tanpa interpretasi	4-7
Interpretasi korelasi dengan benar dan kritis	8-10

F. Outlier Analysis (10 poin)

Kriteria	Skor
Tidak mendeteksi outlier	0-3
Hanya menyebut ada outlier	4-7
Analisis lengkap + interpretasi + keputusan	8-10

G. Identifikasi Pola (Patterns) (10 poin)

Kriteria	Skor
Tidak ada analisis pola	0-3

Menyebut pola tanpa penjelasan	4-7
Menjelaskan pola + kemungkinan penyebab	8-10

H. Insight & Interpretasi (20 poin) —

Kriteria	Skor
Tidak ada insight	0-5
Insight umum / template	6-12
Insight spesifik, logis, dan berbasis data	13-20

I. Kerapian & Struktur Laporan (5 poin)

Kriteria	Skor
Tidak terstruktur	0-2
Cukup rapi	3-4
Sangat rapi dan sistematis	5

Rekap Bobot

Komponen	Bobot
Pemahaman Konsep	15
Dataset	10
Univariate	15
Bivariate	15
Correlation	10
Outlier	10
Patterns	10
Insight	20
Kerapian	5
Total	100