

LAB 6. Visualisasi Data dengan Seaborn

1. CPMK dan SubCPMK

Mampu membuat visualisasi data menggunakan Python (Matplotlib, Seaborn, Plotly) serta tools Business Intelligence untuk menyajikan informasi secara efektif, informatif, dan mendukung pengambilan keputusan berbasis data.

Sub-CPMK

Mahasiswa mampu:

1. Menggunakan library **Seaborn** untuk membuat visualisasi berbasis statistik
2. Memilih jenis plot yang sesuai berdasarkan tipe data (numerik, kategorikal, distribusi)
3. Menggunakan:
 - o **Statistical plots** (boxplot, violinplot)
 - o **Distribution plots** (distplot/kdeplot)
 - o **Categorical plots** (barplot, countplot)
 - o **Heatmap & correlation matrix**
4. Menginterpretasikan visualisasi statistik untuk menemukan: distribusi data, perbedaan antar kategori, korelasi antar variabel
5. Menerapkan prinsip **pemilihan visualisasi yang tepat (plot selection)**

Indikator Pencapaian

Mahasiswa dinyatakan kompeten jika mampu:

- Memilih plot sesuai tipe data
- Membuat minimal 5 jenis visualisasi Seaborn
- Menginterpretasikan setiap plot secara benar
- Menghindari misuse plot (misalnya salah pakai barplot vs countplot)

2. Dasar Teori

2.1 Konsep Statistical Visualization

Statistical visualization merupakan teknik visualisasi yang digunakan untuk menampilkan **karakteristik statistik dari data**, seperti distribusi, penyebaran, median, variansi, dan hubungan antar variabel. Berbeda dengan visualisasi dasar seperti bar chart atau line chart yang berfokus

pada tren dan perbandingan, statistical visualization bertujuan untuk memahami **struktur internal data**.

Dalam analisis data, memahami distribusi sangat penting karena dua dataset dapat memiliki nilai rata-rata yang sama, tetapi distribusi yang berbeda secara signifikan. Perbedaan ini dapat berdampak langsung pada interpretasi dan pengambilan keputusan. Tanpa visualisasi statistik, informasi seperti skewness (kemiringan distribusi), outlier, atau segmentasi data tidak akan terlihat secara jelas.

Sebagai contoh dalam konteks e-commerce, dua kelompok produk bisa memiliki rata-rata harga yang sama, tetapi:

- satu memiliki distribusi harga yang sempit (konsisten)
- satu lagi memiliki distribusi yang lebar (bervariasi)

Tanpa visualisasi distribusi, kedua kondisi tersebut akan terlihat identik, padahal implikasi bisnisnya sangat berbeda.

Dengan demikian, statistical visualization menjadi bagian penting dalam:

- Exploratory Data Analysis (EDA)
- Validasi asumsi data
- Persiapan sebelum modeling
- Pengambilan keputusan berbasis data

2.2 Pengenalan Seaborn

Seaborn adalah library Python yang dibangun di atas Matplotlib dan dirancang khusus untuk membuat visualisasi statistik dengan lebih mudah dan lebih informatif. Jika Matplotlib bersifat low-level (memberikan kontrol penuh tetapi kompleks), maka Seaborn bersifat high-level dengan pendekatan yang lebih sederhana dan langsung pada analisis.

Salah satu keunggulan utama Seaborn adalah kemampuannya dalam melakukan **statistical aggregation secara otomatis**. Misalnya, ketika menggunakan barplot, Seaborn secara default akan menghitung nilai rata-rata dari suatu variabel tanpa perlu dilakukan secara manual.

Namun, kemudahan ini juga menjadi potensi kesalahan jika pengguna tidak memahami apa yang dihitung. Sebagai contoh:


- Barplot tidak menunjukkan jumlah data, tetapi **rata-rata nilai**
- Countplot menunjukkan jumlah data, bukan rata-rata

Jika perbedaan ini tidak dipahami, maka interpretasi yang dihasilkan bisa salah.

Selain itu, Seaborn menyediakan default styling yang lebih baik, sehingga visualisasi yang dihasilkan lebih mudah dibaca dan lebih profesional tanpa perlu banyak konfigurasi tambahan.

2.3 Statistical Plots

Boxplot



Boxplot merupakan salah satu visualisasi statistik yang digunakan untuk menampilkan ringkasan distribusi data dalam bentuk yang sederhana namun informatif. Boxplot menampilkan beberapa komponen utama, yaitu median, quartile, dan outlier.

Struktur boxplot terdiri dari:

- **Median ($Q2$)**: nilai tengah data
- **Quartile ($Q1$ dan $Q3$)**: membagi data menjadi empat bagian
- **Interquartile Range (IQR)**: rentang antara $Q1$ dan $Q3$
- **Whisker**: batas distribusi normal data
- **Outlier**: data yang berada di luar batas normal

Boxplot sangat efektif untuk:


- Mengidentifikasi outlier

- Membandingkan distribusi antar kategori
- Melihat variasi data secara cepat

Dalam konteks bisnis, boxplot dapat digunakan untuk:


- Mendeteksi harga produk yang tidak wajar
- Menganalisis variasi pembayaran pelanggan
- Mengidentifikasi transaksi ekstrem yang berpotensi anomali

Jika median tidak berada di tengah box, maka distribusi data bersifat tidak simetris (skewed). Hal ini penting karena menunjukkan adanya ketidakseimbangan dalam data.



Violin Plot

Violin plot merupakan pengembangan dari boxplot yang menggabungkan informasi statistik dengan distribusi data dalam bentuk density plot. Jika boxplot hanya menunjukkan ringkasan, maka violin plot menunjukkan **bentuk distribusi secara lebih detail**.



Pada violin plot, lebar kurva menunjukkan kepadatan data:

- Bagian yang lebar → banyak data
- Bagian yang sempit → sedikit data


Violin plot sangat berguna untuk:

- Mengidentifikasi pola distribusi yang kompleks
- Mengetahui apakah data memiliki lebih dari satu puncak (multimodal)
- Membandingkan distribusi antar kategori dengan lebih detail

Dalam konteks e-commerce, violin plot dapat digunakan untuk:

- Mengidentifikasi segmentasi pelanggan
- Melihat variasi harga dalam kategori produk
- Menganalisis pola pembelian yang tidak homogen

Jika data memiliki lebih dari satu puncak, ini bisa mengindikasikan adanya beberapa segmen pasar yang berbeda.




2.4 Distribution Plots

Histogram vs KDE

Distribution plot digunakan untuk memahami bagaimana data tersebar. Dua pendekatan utama adalah histogram dan KDE (Kernel Density Estimation).

Histogram bekerja dengan membagi data ke dalam interval (bins), kemudian menghitung frekuensi pada setiap interval. Histogram memberikan gambaran kasar mengenai distribusi data.



Sementara itu, KDE plot memberikan pendekatan yang lebih halus dengan menampilkan kurva distribusi berdasarkan estimasi probabilitas. KDE mempermudah identifikasi pola distribusi karena tidak bergantung pada jumlah bin.

Distribusi data dapat dikategorikan menjadi:

- **Normal distribution** → simetris
- **Right-skewed** → condong ke kanan (banyak nilai kecil)
- **Left-skewed** → condong ke kiri (banyak nilai besar)


Dalam konteks bisnis:

- Distribusi harga membantu memahami segmentasi pasar
- Distribusi transaksi membantu melihat perilaku pelanggan
- Distribusi data membantu mendeteksi bias atau ketidakseimbangan

2.5 Categorical Plots

Barplot

Barplot digunakan untuk menampilkan nilai agregasi (biasanya rata-rata) dari variabel numerik berdasarkan kategori.



Perbedaan penting dengan countplot:

- Countplot → jumlah data
- Barplot → nilai rata-rata


Kesalahan umum terjadi ketika barplot digunakan untuk mengukur jumlah data, padahal sebenarnya menampilkan nilai rata-rata.

Dalam konteks bisnis:

- Rata-rata harga per kategori
- Rata-rata rating produk
- Performa kategori berdasarkan nilai tertentu

Countplot

Countplot digunakan untuk menghitung jumlah observasi pada setiap kategori. Visualisasi ini sangat sederhana tetapi penting untuk memahami distribusi kategori dalam data.



Countplot menjawab pertanyaan:

- Kategori mana yang paling banyak muncul?
- Apakah data seimbang atau tidak?

Dalam konteks e-commerce:

- Mengetahui kategori produk paling populer
- Mengidentifikasi ketimpangan distribusi produk

2.6 Heatmap & Correlation Matrix

Heatmap digunakan untuk memvisualisasikan hubungan antar variabel dalam bentuk matriks korelasi. Korelasi menunjukkan seberapa kuat hubungan antara dua variabel.



Nilai korelasi berkisar antara:

- +1 → hubungan positif sempurna
- 0 → tidak ada hubungan
- -1 → hubungan negatif sempurna

Heatmap mempermudah identifikasi:

- Variabel yang saling berhubungan
- Variabel independen
- Pola multivariat dalam data

Namun penting untuk dipahami:

Korelasi tidak berarti kausalitas

Dalam konteks bisnis:

- Mengidentifikasi faktor yang mempengaruhi harga
- Menentukan variabel penting untuk analisis lanjutan
- Mendukung pengambilan keputusan berbasis data

3. Tujuan Praktikum

Setelah menyelesaikan praktikum ini, mahasiswa diharapkan mampu:

- 1) Menggunakan library Seaborn untuk membuat visualisasi statistik pada dataset.
- 2) Memilih jenis plot yang sesuai berdasarkan karakteristik data, baik numerik maupun kategorikal.
- 3) Membuat dan menginterpretasikan:
 - a. boxplot untuk mendeteksi outlier dan melihat sebaran data
 - b. violinplot untuk memahami bentuk distribusi data
 - c. distribution plot seperti histogram dan kdeplot untuk menganalisis distribusi variabel numerik
 - d. countplot untuk menghitung frekuensi kategori
 - e. barplot untuk membandingkan nilai agregat antar kategori
 - f. heatmap untuk menganalisis korelasi antar variabel numerik
- 4) Mengidentifikasi pola distribusi data seperti:
 - a. simetris
 - b. skewed
 - c. multimodal
- 5) Menghubungkan hasil visualisasi statistik dengan konteks analisis data dan pengambilan keputusan.

4. Langkah Praktikum

4.1 Import Library

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Style visualisasi
sns.set_theme(style="whitegrid")

# Menampilkan seluruh kolom jika diperlukan
pd.set_option('display.max_columns', None)
```

4.2 Load Dataset (Olist - reuse)

```
orders_path = '../dataset/olist_orders_dataset.csv'
items_path = '../dataset/olist_order_items_dataset.csv'
products_path = '../dataset/olist_products_dataset.csv'

df_orders = pd.read_csv(orders_path)
df_items = pd.read_csv(items_path)
```

```
df_products = pd.read_csv(products_path)

print("df_orders:", df_orders.shape)
print("df_items:", df_items.shape)
print("df_products:", df_products.shape)
```

4.3 Pemeriksaan Awal Dataset

```
display(df_orders.head())
display(df_items.head())
display(df_products.head())
```

4.4 Data Preparation

Pada tahap ini dilakukan beberapa langkah persiapan agar data siap divisualisasikan. Karena beberapa plot memerlukan kolom numerik dan kategorikal dalam satu dataframe, dataset perlu digabungkan.

```
# Konversi datetime
df_orders['order_purchase_timestamp'] =
pd.to_datetime(df_orders['order_purchase_timestamp'])

# Tambahkan kolom bulan
df_orders['order_month'] =
df_orders['order_purchase_timestamp'].dt.to_period('M')

# Merge dataset
df = df_orders.merge(df_items, on='order_id',
how='inner')
df = df.merge(df_products, on='product_id', how='left')

print("Shape data gabungan:", df.shape)
display(df.head())
```

4.5 Pengecekan Missing Values

Pada visualisasi statistik, missing value bisa mengganggu interpretasi, terutama pada distribution plots dan correlation matrix. Karena itu, mahasiswa harus memeriksa missing values terlebih dahulu.

```
missing_values =
df.isnull().sum().sort_values(ascending=False)
missing_values[missing_values > 0].head(20)
```

4.6 Distribution Plot: Histogram dan KDE Plot

Visualisasi ini digunakan untuk memahami distribusi variabel numerik, misalnya price. Histogram menunjukkan frekuensi, sedangkan KDE menunjukkan bentuk kurva distribusi yang lebih halus.

```
plt.figure(figsize=(10, 5))
sns.histplot(data=df, x='price', bins=50, kde=True,
color='skyblue')

plt.title('Distribusi Harga Produk')
plt.xlabel('Harga Produk')
plt.ylabel('Frekuensi')
plt.show()
```

Interpretasi yang diharapkan

Mahasiswa mengamati:

- apakah distribusi simetris atau skewed
- apakah mayoritas produk berada di harga rendah atau tinggi
- apakah ada indikasi ekor distribusi yang panjang

4.7 Boxplot

Boxplot digunakan untuk melihat median, quartile, dan mendeteksi outlier. Plot ini sangat penting dalam analisis awal karena dapat menunjukkan apakah data memiliki nilai ekstrem.

```
plt.figure(figsize=(10, 5))
sns.boxplot(data=df, x='price', color='orange')

plt.title('Boxplot Harga Produk')
plt.xlabel('Harga Produk')
plt.show()
```

Interpretasi yang diharapkan

Mahasiswa mengamati:

- posisi median
- panjang box
- banyaknya outlier
- apakah distribusi cenderung condong ke salah satu sisi

4.8 Violin Plot

Violin plot digunakan untuk melihat distribusi data secara lebih rinci dibanding boxplot. Plot ini menunjukkan density atau kepadatan distribusi.

Contoh di bawah membandingkan distribusi harga berdasarkan kategori teratas.

```
top_categories =
df['product_category_name'].value_counts().head(5).index
df_top =
df[df['product_category_name'].isin(top_categories)]

plt.figure(figsize=(12, 6))
sns.violinplot(data=df_top, x='product_category_name',
y='price', palette='pastel')

plt.title('Distribusi Harga Produk pada 5 Kategori
Teratas')
plt.xlabel('Kategori Produk')
plt.ylabel('Harga Produk')
plt.xticks(rotation=45)
plt.show()
```

Interpretasi yang diharapkan

Mahasiswa mengamati:

- kategori mana yang memiliki distribusi harga paling lebar
- apakah ada kategori dengan konsentrasi harga pada rentang tertentu
- apakah distribusi antar kategori seragam atau berbeda

4.9 Countplot

Countplot digunakan untuk menghitung jumlah observasi pada setiap kategori. Ini cocok untuk data kategorikal.

```
plt.figure(figsize=(12, 5))
sns.countplot(
    data=df,
    y='product_category_name',
```

```

order=df['product_category_name'].value_counts().head(10)
).index,
    palette='viridis'
)

plt.title('Top 10 Kategori Produk Berdasarkan Frekuensi')
plt.xlabel('Jumlah Data')
plt.ylabel('Kategori Produk')
plt.show()

```

Interpretasi yang diharapkan

Mahasiswa mengamati:

- kategori mana yang paling sering muncul
- apakah distribusi kategori merata atau tidak
- apakah ada dominasi kategori tertentu

4.10 Barplot

Barplot digunakan untuk menampilkan nilai agregat (default: mean) dari variabel numerik berdasarkan kategori.

Contoh berikut menampilkan rata-rata harga berdasarkan kategori teratas.

```

avg_price_category = (
    df.groupby('product_category_name',
as_index=False) ['price']
        .mean()
        .sort_values(by='price', ascending=False)
        .head(10)
)

plt.figure(figsize=(12, 5))
sns.barplot(data=avg_price_category,
x='product_category_name', y='price', palette='magma')

plt.title('Top 10 Kategori Berdasarkan Rata-rata Harga')
plt.xlabel('Kategori Produk')
plt.ylabel('Rata-rata Harga')

```

```
plt.xticks(rotation=45)
plt.show()
```

Interpretasi yang diharapkan

Mahasiswa mengamati:

- kategori mana yang memiliki rata-rata harga tertinggi
- apakah kategori yang paling sering muncul juga yang paling mahal
- bagaimana perbedaan countplot dan barplot menghasilkan insight yang berbeda

4.11 Correlation Matrix dan Heatmap

Heatmap digunakan untuk memvisualisasikan hubungan antar variabel numerik. Ini membantu mahasiswa memahami korelasi antar fitur.

```
corr = df[['price', 'freight_value', 'order_item_id',
          'product_name_lenght',
          'product_description_lenght',
          'product_photos_qty', 'product_weight_g']].corr()

plt.figure(figsize=(10, 6))
sns.heatmap(corr, annot=True, cmap='coolwarm',
            fmt='.2f')

plt.title('Correlation Matrix Variabel Numerik')
plt.show()
```

Interpretasi yang diharapkan

Mahasiswa mengamati:

- pasangan variabel dengan korelasi paling kuat
- apakah korelasi bersifat positif atau negatif
- apakah terdapat variabel yang hampir tidak berkorelasi

4.12 Perbandingan Plot Berdasarkan Tipe Data

- **Histogram / KDE** → distribusi data numerik
- **Boxplot / Violinplot** → sebaran, median, outlier, density
- **Countplot** → jumlah data kategori

- **Barplot** → rata-rata nilai numerik per kategori
- **Heatmap** → korelasi antar variabel numerik

Mahasiswa harus memahami bahwa satu jenis plot tidak bisa dipakai untuk semua situasi.

5. Hasil dan Pembahasan

5.1 Distribusi Data (KDE / Histogram)

Observasi

Histogram yang dilengkapi dengan KDE menunjukkan bahwa distribusi harga produk tidak simetris. Sebagian besar data terkonsentrasi pada rentang harga rendah, sementara frekuensi menurun tajam pada harga yang lebih tinggi. Kurva KDE memperlihatkan bentuk distribusi yang condong ke kanan dengan ekor panjang hingga nilai harga yang sangat tinggi.

Tidak terlihat pola distribusi normal (bell-shaped), melainkan distribusi yang sangat tidak merata dengan kepadatan tinggi di area harga rendah

Analisis

Distribusi seperti ini disebut **right-skewed distribution (positively skewed)**, yang berarti mayoritas data berada di sisi kiri (nilai rendah), sementara sebagian kecil data memiliki nilai sangat tinggi.

Dalam konteks e-commerce, pola ini sangat umum karena:

- Produk murah lebih banyak tersedia
- Produk murah memiliki frekuensi pembelian lebih tinggi
- Produk mahal hanya sebagian kecil dari katalog

KDE membantu memperjelas bahwa distribusi tidak hanya tidak simetris, tetapi juga memiliki kepadatan tinggi pada rentang tertentu, yang menunjukkan adanya konsentrasi pasar pada segmen harga tertentu.

Insight

- Mayoritas produk berada pada **segmen harga rendah hingga menengah**
- Distribusi harga sangat tidak merata dan memiliki **long tail**
- Produk mahal memiliki frekuensi rendah tetapi tetap ada

Implikasi Bisnis

- Model bisnis cenderung **volume-driven (berbasis jumlah transaksi)**
- Strategi promosi lebih efektif pada produk harga rendah
- Produk premium dapat menjadi sumber margin tinggi, meskipun volumenya kecil

5.2 Analisis Outlier dan Variasi Data (Boxplot)

Observasi

Boxplot menunjukkan bahwa sebagian besar data berada pada rentang harga rendah, dengan median yang berada dekat dengan batas bawah. Terlihat banyak titik di luar whisker yang menandakan keberadaan outlier, terutama pada nilai harga yang tinggi.

Whisker memanjang ke arah kanan, menunjukkan distribusi yang tidak simetris.

Analisis

Posisi median yang tidak berada di tengah box menunjukkan bahwa distribusi tidak seimbang. Banyaknya outlier menunjukkan adanya variasi harga yang cukup ekstrem, yang tidak mengikuti pola mayoritas data.

Outlier ini bisa berasal dari:

- Produk premium
- Kesalahan data
- Variasi kategori produk yang sangat berbeda

Boxplot memperkuat temuan dari histogram bahwa distribusi harga tidak normal dan memiliki penyebaran yang tidak merata.

Insight

- Terdapat **banyak outlier harga tinggi**
- Distribusi harga sangat tidak simetris
- Variasi harga antar produk cukup besar

Implikasi Bisnis

- Perlu evaluasi apakah outlier adalah:
 - peluang (produk premium)
 - atau anomali data
- Strategi pricing perlu mempertimbangkan distribusi yang tidak merata

5.3 Violinplot (Analisis Distribusi)

Observasi

Violin plot menunjukkan distribusi harga untuk beberapa kategori produk. Setiap kategori memiliki bentuk distribusi yang berbeda, dengan beberapa kategori menunjukkan penyebaran yang lebih lebar dibandingkan yang lain.

Bagian yang melebar pada violin menunjukkan area dengan kepadatan data tinggi, sedangkan bagian yang menyempit menunjukkan sedikit data.

Analisis

Perbedaan bentuk violin antar kategori menunjukkan bahwa setiap kategori memiliki karakteristik harga yang berbeda. Beberapa kategori memiliki distribusi yang sempit (harga relatif konsisten), sementara yang lain memiliki distribusi yang lebih luas (harga bervariasi).

Jika terdapat lebih dari satu puncak pada violin, ini menunjukkan adanya **multi-segmen dalam satu kategori**.

Insight

- Setiap kategori memiliki **struktur harga yang berbeda**
- Ada kategori dengan variasi harga tinggi dan rendah secara bersamaan
- Potensi segmentasi pasar dalam kategori tertentu

Implikasi Bisnis

- Strategi harga tidak bisa disamaratakan antar kategori
- Perlu segmentasi produk dalam kategori
- Peluang untuk diferensiasi produk berdasarkan harga

5.4 Categorical Analysis (Barplot & Countplot)

Observasi

Countplot menunjukkan jumlah data pada setiap kategori, sedangkan barplot menunjukkan rata-rata harga per kategori. Dari kedua plot ini terlihat bahwa kategori dengan frekuensi tinggi tidak selalu memiliki rata-rata harga yang tinggi.

Analisis

Perbedaan ini menunjukkan bahwa:

- Countplot mengukur **volume (berapa banyak data)**

- Barplot mengukur **nilai agregat (berapa besar rata-rata)**

Kesalahan umum adalah menganggap kategori dengan frekuensi tinggi sebagai kategori paling “bernilai”, padahal belum tentu demikian.

Insight

- Kategori populer ≠ kategori mahal
- Volume dan value adalah dua dimensi yang berbeda
- Beberapa kategori mungkin:
 - tinggi volume, rendah harga
 - rendah volume, tinggi harga

Implikasi Bisnis

- Perlu strategi berbeda:
 - kategori volume → fokus pada jumlah transaksi
 - kategori premium → fokus pada margin
- Tidak semua kategori harus dioptimalkan dengan strategi yang sama

5.5 Correlation Heatmap

Observasi

Heatmap menunjukkan bahwa sebagian besar nilai korelasi antar variabel berada pada level rendah hingga sedang. Tidak terdapat pasangan variabel dengan korelasi yang sangat kuat.

Analisis

Korelasi yang rendah menunjukkan bahwa variabel dalam dataset relatif independen satu sama lain. Hal ini berarti tidak ada hubungan linear yang kuat antar variabel.

Namun, ini tidak berarti tidak ada hubungan sama sekali. Bisa jadi hubungan yang ada bersifat:

- non-linear
- dipengaruhi variabel lain
- atau tersembunyi dalam segmentasi tertentu

Insight

- Tidak ada hubungan linear kuat antar variabel utama
- Variabel cenderung independen
- Perlu analisis lanjutan untuk menemukan hubungan yang lebih kompleks

Implikasi Bisnis

- Tidak bisa mengandalkan satu variabel untuk memprediksi variabel lain
- Perlu pendekatan multivariat atau modeling lanjutan
- Analisis korelasi membantu memahami kompleksitas data

Sintesis Insight (Integrasi Semua Plot)

Jika seluruh hasil visualisasi digabungkan, maka pola yang muncul adalah:

- Distribusi data sangat tidak merata (skewed)
- Banyak outlier menunjukkan variasi ekstrem
- Kategori memiliki karakteristik yang berbeda
- Volume dan nilai tidak selalu sejalan
- Hubungan antar variabel tidak kuat secara linear

Kesimpulan Analitik

Secara keseluruhan, visualisasi menggunakan Seaborn memberikan pemahaman yang lebih dalam dibandingkan visualisasi dasar. Data tidak hanya menunjukkan tren, tetapi juga struktur distribusi, variasi, dan hubungan antar variabel.

Analisis menunjukkan bahwa data e-commerce memiliki karakteristik:

- dominasi produk harga rendah
- variasi harga yang tinggi
- distribusi yang tidak simetris
- hubungan antar variabel yang kompleks

Hal ini menegaskan bahwa analisis statistik melalui visualisasi sangat penting untuk memahami data secara lebih mendalam sebelum mengambil keputusan atau melakukan analisis lanjutan.

6. Soal Praktikum

Instruksi Umum

Gunakan dataset **Olist E-Commerce** yang telah digunakan pada praktikum.

Setiap jawaban **WAJIB** mencakup:

- kode visualisasi

- hasil grafik
- interpretasi (observasi + analisis + insight)

Soal 1 – Analisis Distribusi (Histogram + KDE)

Buat visualisasi distribusi untuk variabel:

- price

Gunakan:

- `sns.histplot()` dengan KDE

Pertanyaan:

- Bagaimana bentuk distribusi data?
- Apakah distribusi bersifat normal, skewed, atau multimodal?
- Pada rentang harga berapa data paling terkonsentrasi?
- Apa arti distribusi tersebut dalam konteks e-commerce?

Soal 2 – Analisis Outlier (Boxplot)

Buat visualisasi **boxplot** untuk:

- price

Pertanyaan:

- Apakah terdapat outlier? Jelaskan bagaimana Anda mengetahuinya
- Bagaimana posisi median terhadap distribusi data?
- Apakah distribusi data simetris?
- Apa kemungkinan penyebab munculnya outlier?

Soal 3 – Analisis Distribusi Kategori (Violin Plot)

Buat **violin plot** untuk:

- price berdasarkan **5 kategori produk teratas**

Pertanyaan:

- Kategori mana yang memiliki variasi harga paling tinggi?
- Apakah ada kategori dengan distribusi harga yang sempit?
- Apakah terdapat indikasi multi-segmen dalam kategori tertentu?
- Apa implikasi distribusi ini terhadap strategi harga?

Soal 4 – Perbandingan Countplot vs Barplot

Buat dua visualisasi:

1. **Countplot** untuk:
 - product_category_name (Top 10)
2. **Barplot** untuk:
 - rata-rata price per kategori (Top 10)

Pertanyaan:

- Apa perbedaan informasi yang ditampilkan oleh kedua plot tersebut?
- Apakah kategori dengan frekuensi tertinggi juga memiliki harga tertinggi?
- Mengapa countplot dan barplot tidak boleh dipertukarkan?
- Insight apa yang muncul ketika kedua plot dibandingkan?

Soal 5 – Analisis Korelasi (Heatmap)

Buat **heatmap correlation matrix** untuk variabel numerik berikut:

- price
- freight_value
- product_weight_g
- product_photos_qty
- dan variabel numerik lain yang relevan

Pertanyaan:

- Variabel mana yang memiliki korelasi paling kuat?
- Apakah hubungan tersebut positif atau negatif?
- Apakah terdapat variabel yang hampir tidak berkorelasi?
- Apa arti hasil ini dalam konteks analisis data?

Soal 6 – Evaluasi Pemilihan Plot (Critical Thinking)

Untuk setiap jenis plot berikut, jelaskan:

- kapan digunakan
- kapan tidak boleh digunakan

Plot:

- histogram / KDE
- boxplot
- violinplot
- countplot
- barplot

- heatmap

Pertanyaan:

- Apa kesalahan paling umum dalam penggunaan plot tersebut?
- Berikan contoh misuse plot dan dampaknya terhadap interpretasi

Soal 7 – Analisis Terintegrasi (Mini Dashboard Seaborn)

Buat minimal **4 visualisasi Seaborn** dalam satu analisis:

- 1 distribution plot
- 1 boxplot / violinplot
- 1 categorical plot
- 1 heatmap

Pertanyaan:

- Apa hubungan antar hasil visualisasi tersebut?
- Insight apa yang tidak terlihat jika hanya melihat satu plot saja?
- Bagaimana visualisasi membantu memahami data secara lebih dalam?

8. Tugas Laporan

Instruksi Umum

Mahasiswa diminta menggunakan **dataset masing-masing** dengan kriteria yang telah ditentukan sebelumnya

Kriteria Dataset

- Memiliki minimal:
 - 2 variabel numerik
 - 1 variabel kategorikal
 - 1 variabel waktu (opsional, tapi direkomendasikan)
- Dataset harus cukup kompleks (≥ 500 baris disarankan)
- Sumber:
 - Kaggle
 - Open data
 - Data internal (jika ada)

Constraint Utama

Laporan akan dianggap **tidak valid** jika:

- hanya menampilkan grafik tanpa analisis
- tidak menjelaskan alasan pemilihan plot
- tidak membahas distribusi data
- tidak membahas outlier atau variasi data

Struktur Laporan

1. Pendahuluan

Berisi:

- Latar belakang dataset
- Permasalahan yang ingin dianalisis
- Tujuan analisis

Fokus:

- bukan deskripsi dataset
- tapi **apa yang ingin dipahami dari data**

2. Deskripsi Dataset

Berisi:

- Sumber dataset
- Jumlah baris dan kolom
- Penjelasan variabel
- Tipe data (numerik/kategorikal)

Tambahan wajib:

- Identifikasi variabel mana yang akan digunakan untuk:
 - distribusi
 - kategorikal
 - korelasi

3. Data Preparation

Berisi:

- Penanganan missing values
- Filtering data (jika ada)
- Transformasi data (datetime, grouping, dll)

WAJIB:

- jelaskan **alasan setiap langkah**

4. Analisis Statistical Visualization (Core Section)

4.1 Distribution Analysis (Histogram + KDE)

Mahasiswa WAJIB:

- membuat histogram + KDE

Dan menjelaskan:

- bentuk distribusi (normal / skewed / multimodal)
- area konsentrasi data
- interpretasi statistik

WAJIB TAMBAHAN:

- jelaskan **kenapa menggunakan KDE**

4.2 Outlier Analysis (Boxplot)

Mahasiswa WAJIB:

- membuat boxplot

Dan menjelaskan:

- keberadaan outlier
- penyebab potensial
- dampak outlier terhadap analisis

WAJIB:

- bukan hanya “ada outlier”
- tapi “apa artinya”

4.3 Distribution Comparison (Violin Plot)

Mahasiswa WAJIB:

- membuat violin plot berdasarkan kategori

Dan menjelaskan:

- perbedaan distribusi antar kategori
- apakah terdapat multi-segmen
- variasi data

WAJIB:

- bandingkan antar kategori (bukan satu kategori saja)

4.4 Categorical Analysis (Countplot vs Barplot)

Mahasiswa WAJIB:

- membuat:
 - countplot
 - barplot

Dan menjelaskan:

- perbedaan keduanya
- kapan digunakan
- insight yang berbeda

WAJIB:

- jelaskan **kesalahan jika tertukar**

4.5 Correlation Analysis (Heatmap)

Mahasiswa WAJIB:

- membuat correlation matrix

Dan menjelaskan:

- hubungan antar variabel
- kekuatan korelasi
- kemungkinan interpretasi

WAJIB:

- jelaskan: “korelasi tidak sama dengan sebab-akibat”

5. Analisis Terintegrasi (Critical Section)

Mahasiswa harus menggabungkan semua hasil analisis:

Jawab:

- Bagaimana distribusi data mempengaruhi insight?
- Apakah outlier mempengaruhi interpretasi?
- Apakah kategori memiliki karakteristik berbeda?
- Apakah variabel saling berhubungan?

6. Kesimpulan

Berisi:

- ringkasan insight utama
- jawaban terhadap tujuan analisis
- temuan paling penting

7. Rekomendasi

Berisi:

- rekomendasi berbasis data
- strategi atau tindakan yang bisa dilakukan
- peluang analisis lanjutan

WAJIB:

- tidak boleh generik
- harus berbasis hasil visualisasi

Rubrik Penilaian LAB 6 – Visualisasi Data dengan Seaborn

No	Komponen	Bobot	Excellent	Good	Fair	Poor
1	Dataset & Problem Framing	10	Dataset kompleks, relevan, tujuan analisis jelas dan terarah	Dataset cukup relevan, tujuan cukup jelas	Dataset sederhana, tujuan kurang spesifik	Dataset tidak sesuai, tujuan tidak jelas
2	Data Preparation	15	Cleaning, transformasi, dan handling missing tepat + alasan jelas	Cleaning benar, penjelasan kurang dalam	Cleaning dasar, ada langkah terlewat	Tidak ada atau banyak kesalahan
3	Pemilihan Plot (Plot Selection)	20	Semua plot sesuai tipe data dan tujuan analisis	Sebagian besar tepat	Beberapa plot tidak sesuai	Salah memilih plot
4	Distribution Analysis (Histogram & KDE)	10	Menjelaskan distribusi (skewness, density, segmentasi) dengan benar	Menjelaskan distribusi secara umum	Hanya menyebut bentuk tanpa analisis	Tidak memahami distribusi
5	Outlier Analysis (Boxplot)	10	Mengidentifikasi outlier + menjelaskan dampaknya	Menemukan outlier tanpa analisis lanjut	Hanya menyebut ada outlier	Tidak memahami boxplot
6	Distribution Comparison (Violin Plot)	10	Membandingkan distribusi antar kategori secara mendalam	Membandingkan secara umum	Analisis terbatas	Tidak memahami violin plot
7	Categorical Analysis (Countplot vs Barplot)	10	Memahami perbedaan count vs mean + insight jelas	Memahami sebagian perbedaan	Masih tertukar	Tidak memahami perbedaan
8	Correlation Analysis (Heatmap)	10	Interpretasi korelasi benar + memahami keterbatasannya	Interpretasi cukup benar	Hanya membaca angka	Salah interpretasi
9	Integrasi Insight (Cross-Plot Analysis)	10	Mampu menghubungkan semua plot menjadi insight terpadu	Ada usaha integrasi	Analisis terpisah	Tidak ada integrasi
10	Insight & Rekomendasi	5	Insight tajam, berbasis data, rekomendasi actionable	Insight ada tapi umum	Insight dangkal	Tidak ada insight